Отчёт по лабораторным работам по информационному поиску

Адаптация корпуса и отчётов под источники GeoNames и PubMed

Лабораторная работа № 1 «Добыча корпуса документов»

Корпус на основе GeoNames и PubMed

Описание

Цель работы — подготовить корпус документов, который далее используется для токенизации, построения индекса и булевого поиска. В качестве источников были выбраны GeoNames и PubMed.

GeoNames даёт большое количество HTML-страниц с географическими объектами: населённые пункты, административные единицы и другие объекты. PubMed даёт страницы научных записей со стабильными URL и полезной текстовой метаинформацией: заголовком, аннотацией, авторами, журналом и годом публикации.

Почему были выбраны именно эти источники

- Оба сайта содержат большой объём документов, что позволяет собрать корпус свыше 30 000 документов.
- Страницы доступны по стабильным URL и могут быть обработаны обычным HTML-краулером без обязательного перехода к PDF.
- Для обоих источников существует внешний поиск, поэтому корпус подходит под требования лабораторной работы.

Структура документов

Для GeoNames документом считается HTML-страница конкретного географического объекта. На странице обычно есть название объекта, координаты, страна, административная принадлежность и связанные названия.

Для PubMed документом считается HTML-страница записи статьи. Она содержит заголовок, авторов, журнал, дату, PMID, ключевые метаданные и, во многих случаях, аннотацию.

После скачивания сырые HTML-документы сохраняются в MongoDB. Затем программа выделяет из них очищенный текст и сохраняет его в каталог docs/, а метаданные — в файл meta.tsv.

Существующие поисковые средства

Для GeoNames можно использовать встроенный поиск по сайту и поиск по домену через Google.

Для PubMed можно использовать встроенный поиск PubMed по базе публикаций, а также поиск по домену через Google.

Примеры запросов к внешним поисковым системам

GeoNames: Belgrade site:geonames.org, Novi Sad site:geonames.org.

PubMed: stroke rehabilitation site:pubmed.ncbi.nlm.nih.gov, lung cancer biomarker site:pubmed.ncbi.nlm.nih.gov.

Недостатки внешней выдачи: часть результатов может вести на служебные страницы, дубликаты или документы со слабым текстовым наполнением.

Результаты

- Размер «сырых» данных: 543 МБ
- Количество документов: 65 269
- Размер текста, выделенного из «сырых» данных: 378 МБ.
- Средний размер документа: 7 КБ.
- Средний объем текста в документе: 7КБ очищенного текста.

Выводы

В работе был подготовлен корпус документов из двух открытых источников — GeoNames и PubMed. Оба источника дают устойчивые HTML-страницы, пригодные для автоматической загрузки, очистки текста и дальнейшей индексации.

Подготовленный корпус может использоваться в следующих лабораторных работах по информационному поиску.

Лабораторная работа № 2
«Поисковый робот»

Краулер для GeoNames и PubMed

Описание

Цель работы — реализовать поискового робота, который автоматически обходит открытые интернет-источники, скачивает HTML-страницы и сохраняет их в базе данных для дальнейшей обработки.

В данной версии проекта робот адаптирован под два новых источника: GeoNames и PubMed.

Принцип работы

Программа получает путь к YAML-конфигурации. В конфигурации задаются параметры MongoDB, количество потоков, задержки между запросами, настройки повторной проверки документов и параметры сидирования URL.

Для GeoNames робот формирует ссылки на HTML-страницы географических объектов на основе официального дампа идентификаторов. Для PubMed робот получает PMID через API E-utilities и превращает их в ссылки на HTML-страницы записей публикаций.

Каждый URL нормализуется, после чего страница скачивается и сохраняется в MongoDB вместе с адресом, именем источника и временем загрузки.

Журнал выполнения и решение проблем

Основной задачей было заменить встроенные сидеры ACL и arXiv на генераторы URL для GeoNames и PubMed, не ломая остальной пайплайн проекта.

Для GeoNames была добавлена логика чтения архива с официальным дампом и построения URL вида https://sws.geonames.org/<id>/.

Для PubMed была добавлена логика обращения к E-utilities, получения списка PMID по запросу и датам, а затем построения URL вида https://pubmed.ncbi.nlm.nih.gov/<pmid>/.

Дополнительно были настроены отдельные интервалы между запросами к разным хостам, чтобы не выполнять слишком частые обращения.

Хранимые данные

В коллекции URL хранится информация о состоянии обхода, источнике и времени следующей проверки.

В коллекции документов сохраняются URL, сырой HTML, источник и время обкачки.

Такой подход позволяет останавливать робота и затем продолжать обход без потери прогресса.

Выводы

В результате работы поисковый робот был успешно адаптирован под новые источники GeoNames и PubMed.

Робот сохраняет сырые HTML-документы и метаинформацию в MongoDB, поддерживает возобновление после остановки и может использоваться как база для последующих этапов обработки текста.

Лабораторная работа № 3
«Токенизация»

Токенизация смешанного корпуса GeoNames + PubMed

Описание

Цель работы — реализовать токенизацию текстов документов корпуса, чтобы затем использовать токены при индексации и поиске.

Корпус состоит из документов двух разных типов: краткие географические страницы GeoNames и научные страницы PubMed с метаданными и аннотациями.

Правила токенизации

В качестве токена рассматривается непрерывная последовательность букв или цифр. Пробелы и знаки пунктуации считаются разделителями.

Перед добавлением токена выполняется понижение регистра. При необходимости включается стемминг.

Составные формы с дефисом могут сохраняться как единый токен, если это полезно для технических и предметных терминов.

Достоинства и недостатки подхода

Преимущества: простая реализация, линейная сложность по длине текста, одинаковая обработка для всех документов корпуса.

Недостатки: в данных PubMed могут встречаться служебные маркеры и сокращения, а в GeoNames — короткие служебные обозначения, коды и цифровые поля.

Примеры неудачных токенов

Коды и краткие обозначения вроде rs, pmid или числовые идентификаторы могут оставаться в корпусе и увеличивать шум.

Формы с апострофом или редкими спецсимволами могут делиться неидеально.

Отдельные HTML-артефакты или остатки служебного текста желательно лучше чистить до токенизации.

Результаты и статистика

Количество обработанных документов: 58866.

Суммарный объем входного текста: 529704878 байт.

Общее число токенов: 70584169.

Средняя длина токена: 6.00442 символа.

Время токенизации: 6.38815 секунд.

Плотность токенов: 136.45 токенов на килобайт.

Время выполнения и скорость

Токенизация выполняется за один проход по тексту, поэтому время работы примерно пропорционально объему входных данных.

Ускорить программу можно распараллеливанием по документам, чтением крупными блоками и уменьшением количества промежуточных выделений памяти.

Выводы

Токенизация для корпуса GeoNames + PubMed реализована и пригодна для следующих лабораторных работ.

При этом на смешанном корпусе остаются шумные токены, поэтому качество можно дополнительно улучшать за счёт более строгой очистки и специальных правил нормализации.

Лабораторная работа № 4
«Стемминг»

Стемминг на корпусе GeoNames + PubMed

Описание

Цель работы — добавить в поисковую систему стемминг, чтобы поиск меньше зависел от словоформ.

Стемминг применяется согласованно при токенизации, построении индекса и обработке пользовательского запроса.

Особенности на выбранном корпусе

Для PubMed стемминг особенно полезен на английских научных терминах, где встречаются разные грамматические формы одного слова.

Для GeoNames эффект слабее, потому что там много имён собственных, географических названий, кодов и коротких служебных обозначений.

Положительный эффект

После включения стемминга увеличивается полнота поиска: документы находятся не только по точной форме слова, но и по родственным словоформам.

Это особенно заметно на запросах к PubMed, где важны различные формы терминов типа cell / cells, therapy / therapies и т.п.

Где качество может ухудшиться

Качество может ухудшаться, когда разные слова приводятся к одному стему и начинают смешиваться в выдаче.

На GeoNames нежелательно слишком агрессивно обрабатывать имена собственные, потому что точное совпадение названия объекта часто важнее, чем поиск по общей основе слова.

Как улучшить качество

Можно использовать смешанный режим: основную выборку делать по стемам, но дополнительно повышать документы с точным совпадением исходной формы слова.

Для имён собственных, кодов и кратких обозначений можно частично отключать стемминг или обрабатывать их отдельными правилами.

Выводы

Стемминг успешно интегрирован в систему и в целом улучшает полноту поиска на смешанном корпусе.

Для части запросов возможны ухудшения, но они объяснимы и могут быть уменьшены более аккуратной обработкой специальных классов токенов.

Лабораторная работа № 5
«Закон Ципфа»

Анализ распределения терминов для GeoNames + PubMed

Описание

Цель работы — проверить, насколько распределение терминов в собранном корпусе соответствует закону Ципфа.

Для этого термины сортируются по убыванию частоты, получают ранги, после чего строится график частота–ранг в логарифмической шкале.

Особенности корпуса

Корпус состоит из двух разнородных источников. GeoNames содержит короткие справочные тексты и имена собственные, а PubMed содержит научные заголовки, аннотации и библиографическую информацию.

Из-за смешения источников идеальное распределение нарушается сильнее, чем в однородном корпусе из одного типа текстов.

Причины расхождений с законом Ципфа

В корпусе присутствуют шумовые термины, коды, сокращения и служебные обозначения.

Стемминг и токенизация меняют частоты некоторых групп терминов.

Многочисленные имена собственные из GeoNames и научные аббревиатуры из PubMed увеличивают хвост распределения.

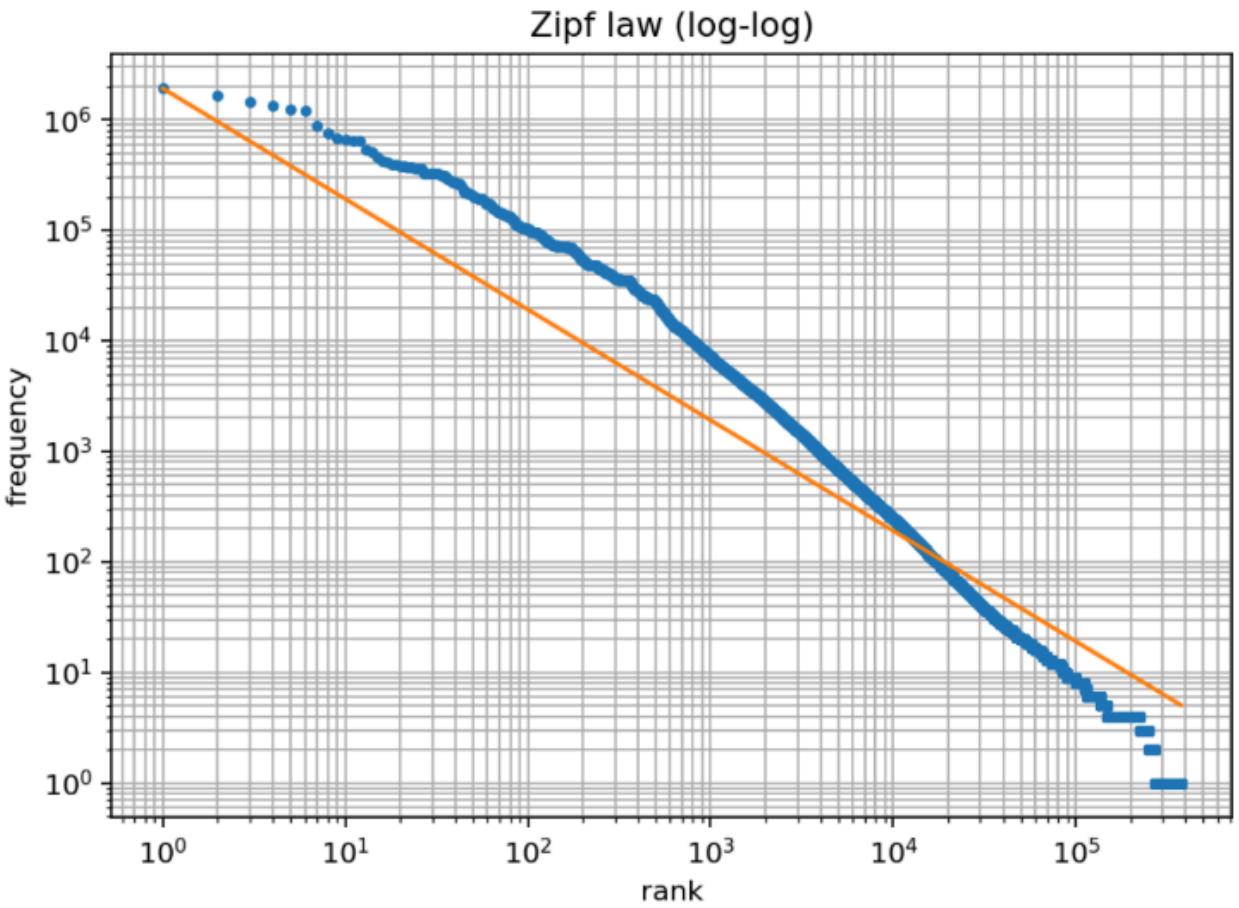

ТОП-10 терминов:

1. The 1914451
2. and 1654312
3. type 1465962
4. namepart 1341016
5. to 1245211
6. of 1204498
7. for 891166
8. is 759947
9. in 683674
10. role 656863

Выводы

Распределение терминов в целом должно сохранять типичную убывающую форму, но для смешанного корпуса GeoNames + PubMed отклонения от идеального закона Ципфа ожидаемо выше.

Основные причины — неоднородность текстов, шум в данных и влияние предобработки.

Лабораторная работа № 7
«Обратный индекс»

Построение индекса по GeoNames + PubMed

Описание

Цель работы — построить обратный индекс, пригодный для булевого поиска по подготовленному корпусу.

Индекс хранится в собственном бинарном формате и состоит из прямого индекса документов, словаря терминов и файлов постингов.

Реализация

Индексатор реализован на C++ и использует внешнюю сортировку, потому что объём данных достаточно велик, а использовать ассоциативные контейнеры по условиям работы нельзя.

На первом этапе формируются пары вида term - doc_id. Затем эти пары сортируются частями, после чего выполняется их слияние в итоговый индекс.

Особенности корпуса

На GeoNames встречается много уникальных имён собственных, а на PubMed
— большое число научных терминов и аббревиатур. Из-за этого словарь может получаться очень большим, а количество уникальных термов — заметно расти.

- Количество документов в индексе: 58866.
- Количество уникальных термов: 376586.
- Количество промежуточных run-файлов: 10.
- Размер файла постингов: 79223688 байт.

Выводы

В результате построен обратный индекс по корпусу GeoNames + PubMed, пригодный для булевого поиска.

Структура индекса и алгоритм внешней сортировки позволяют работать с большим числом документов и термов.

Лабораторная работа № 8
«Булев поиск»

Поиск по индексу GeoNames + PubMed

Описание

Цель работы — реализовать булев поиск по построенному обратному индексу.

Система должна разбирать запросы с логическими операторами и возвращать документы, удовлетворяющие булевому выражению.

Реализация

Поисковый модуль загружает бинарные файлы индекса, разбирает запрос в дерево булева выражения и вычисляет результат через операции над отсортированными списками doc_id.

Для AND выполняется пересечение, для OR — объединение, для NOT — разность с множеством всех документов.

Примеры запросов для нового корпуса

GeoNames: belgrade AND serbia. GeoNames:

(moscow OR berlin) AND river. PubMed: cancer

AND biomarker.

PubMed: (stroke OR rehabilitation) AND !review.

Выводы

Булев поиск по индексу GeoNames + PubMed реализован и корректно работает с операторами AND, OR, NOT и со скобками.

Система может использоваться как базовая поисковая подсистема и дальше расширяться ранжированием, учётом точных совпадений и более сложной обработкой запроса.